

Projet Fouille de Données :

Découvrir et décrire des points d'intérêt
et des événements à partir de médias
géolocalisés

Présentation du projet :	2
Analyse et nettoyage de la base de données :	2
Analyse des attributs :	Erreur ! Signet non défini.
Supprimer les colonnes sans valeurs	3
Supprimer les doublons :	3
Sélectionner un cadre de valeurs entre telle et telle latitude/longitude :	4
Enlever les tuples avec aucun tag	4
Clustering et découverte des points d'intérêts :	5
Utilisation de l'algorithme K-Means	5
Spatial	5
Spatio-temporel	6
Utilisation de l'algorithme Clustering hiérarchique :	7
Utilisation de l'algorithme DBScan :	9
Spatial	9
Spatio-temporel et recherche d'événements	12
Description des points d'intérêts :	14
Introduction	14
Association des tags aux clusters	17

I. Présentation du projet :

La métropole du Grand Lyon souhaite améliorer ses transports en communs et la vie des touristes visitant Lyon. Dans ce contexte, elle a proposé un appel d'offre dont l'objet est de trouver de manière non-intrusive les zones à forte densité de touristes à moindre coût.

Nous disposons donc d'une base de données Flickr avec un jeu de données à 420240 photos, accompagnés d'autres métadonnées, que nous traiterons pour identifier ces points d'intérêt.



II. Analyse et nettoyage de la base de données :

Il est tout d'abord nécessaire de nettoyer les données pour ne seulement garder ce qui est exploitable. Nous pouvons par exemple:

- Enlever les doublons.
- Enlever les données avec bcp d'infos manquantes (par ex. les 3 dernières colonnes)
- Vérifier la cohérence des données (les intrus, localisation douteuse/positions GPS, dates...).
- Enlever les attributs qui s'avèrent inutiles (par ex. la date de téléchargement des photos).

1. Analyse des attributs :


Attribut	Signification	Utilité
ID	l'ID de la photo	A garder
user	l'ID du user qui a pris la photo	A garder
lat	Coordonnées géographiques de la photo	A garder
long		
tags	Thèmes relatifs au contenu de la photo	A garder
title	Titre de la photo	A garder
date_taken_minute	Date de la prise de la photo	A garder
date_taken_hour		

date_taken_day		
date_taken_month		
date_taken_year		
date_upload_minute	Date du téléchargement de la photo	A enlever car cette information ne nous sert pas pour identifier les points d'intérêt.
date_upload_hour		
date_upload_day		
date_upload_month		
date_upload_year		

Nous décidons donc d'enlever les cinq derniers attributs en utilisant le bloc *Column Filter*.

Paramétrage :

- Exclude : date_upload_minute, date_upload_hour, date_upload_day, date_upload_month, date_upload_year.
- Include : les autres attributs.




2. Supprimer les colonnes sans valeurs

Nous avons remarqué que les trois dernières colonnes sont à valeurs nulles. Nous les supprimons donc en utilisant le bloc *Missing Value Column Filter*.

Paramétrage :

- configure : manual, threshold 90%, enforce exclusion



3. Supprimer les doublons :

On utilise le bloc *Group By* sur l'id des photos pour supprimer les doublons.

Paramétrage :

- Group column : id.
- Manuel aggregation : add all.
- Fonction d'agrégation : first.




Table "flickr_data2.csv" - Rows: 420240 Spec - Columns: 19 Properties Flow Variables												
Row ID	D ▲ id	S user	D lat	D long	S tags	S title	I date_taken_minute	I date_taken_hour	I date_taken_day	I date_taken_month	I	
Row 196652	306,667,535	46629827@N00	45.777	4.858	france,zoo,lyon,animaux	P'tits Girafons	48	15	1	11	200!	^
Row 201070	306,667,535	46629827@N00	45.777	4.858	france,zoo,lyon,animaux	P'tits Girafons	48	15	1	11	200!	
Row 185977	306,668,760	46629827@N00	45.777	4.857	france,zoo,lyon	Envoyez... :))	45	15	1	11	200!	
Row 191022	306,668,760	46629827@N00	45.777	4.857	france,zoo,lyon	Envoyez... :))	45	15	1	11	200!	
Row 195749	306,668,760	46629827@N00	45.777	4.857	france,zoo,lyon	Envoyez... :))	45	15	1	11	200!	
Row 186464	1,140,570,280	46629827@N00	45.778	4.855	summer,france,lyon,69,2007,parcd...	Parc de la TÂt...	3	16	14	8	200!	
Row 191512	1,140,570,280	46629827@N00	45.778	4.855	summer,france,lyon,69,2007,parcd...	Parc de la TÂt...	3	16	14	8	200!	

Table "default" - Rows: 168097																	Spec - Columns: 19		Properties		Flow Variables	
Row ID	D ▲ id	S First(user)	D Mean(lat)	D Mean(long)	S First(tags)	S First(title)	D Mean(distance)	D Mean(speed)	D Mean(altitude)	D Mean(acceleration)	D Mean(heading)	D Mean(roll)	S First(destination)	S First(departure)	D Mean(duration)	D Mean(fuel)						
Row0	306,667,535	46629827@N00	45.777	4.858	france,zoo,lyon,animaux	P'tits Girafons	48	15	1	11	2,005	0	12	19	10	▲						
Row1	306,668,760	46629827@N00	45.777	4.857	france,zoo,lyon	Envoyez... :))	45	15	1	11	2,005	0	0	25	7							
Row2	1,140,570,280	46629827@N00	45.778	4.855	summer,france,lyon,69...	Parc de la T...	3	16	14	8	2,007	0	0	17	7							
Row3	3,836,705,013	46629827@N00	45.797	4.833	summer,france,lyon,69...	À%glise ro...	0	15	19	8	2,009	0	0	18	12							
Row4	4,076,280,298	13339562@N06	45.768	4.836	opera,lyon,danse,hip,...	Hip Hop	7	17	4	11	2,009	42	22	4	11							
Row5	4,080,648,277	90493526@N00	45.77	4.832	streetart,france,europ...	Graff by Cy ...	45	16	6	11	2,009	37	21	6	11							



Nous passons de 420240 à 168097 lignes



Remarque :

Nous nous sommes posées la question d'utiliser le *Group By* sur *userID+lat+long* car notre but est de voir le nombre de personnes intéressées par un endroit, alors que plusieurs photos d'un même endroit prises par une même personne pourraient ne pas être pertinentes. Cependant, ce n'est pas une bonne idée de les supprimer. C'est rarement une bonne idée de supprimer des données. On pourrait supprimer des centres d'intérêt en faisant cela.

4. Sélectionner un cadre géographique de valeurs entre telle et telle latitude et longitude :

Selon la fenêtre choisie (la région lyonnaise : oullins, mont d'or, vaulx en velin, bron), nous avons beaucoup de valeurs en moins : 120 523 lignes dans notre cas. Pour cela, on utilise le bloc *Geo-Coordinate Row Filter*.




5. Enlever les tuples avec aucun tag

Nous avons choisi d'enlever les lignes dont la valeur du tag est nulle. Pour cela nous utilisons le bloc *Row Filter*.

Paramétrage :

- configure :
 - select "exclude rows by attribute values",
 - select column to test "Tags",
 - select "only missing values match".




III. Clustering et découverte des points d'intérêts :

1. Utilisation de l'algorithme K-Means

a. Spatial


Nous avons mis en place l'algorithme de clustering k-means paramétré sur la **latitude** et la **longitude** afin d'obtenir des clusters en fonction de l'endroit. Cela permet de séparer les quartiers de Lyon. Selon le nombre de clusters choisi, les clusters peuvent correspondre soit à des quartiers (60 clusters) soit à des arrondissements (15 clusters), soit aux 4 cardinalités (nord,sud,est,ouest) (4 clusters).




→ Nous avons remarqué que plus on augmente le nombre de clusters, plus les zones sont bien définies.

→ Un centre d'intérêt est un endroit très dense en nombre de photos prises. Un cluster est dense plus le nombre de photos est élevé pour une taille spatiale (petite) du cluster.


4 clusters



15 clusters



60 clusters




b. Spatio-temporel

On paramètre l'algorithme K-means paramétré selon la latitude, la longitude et la date (jour, mois, année) de la photo. Les clusters calculés correspondront à des photos prises plutôt au même endroit, plutôt en même temps.

- Les résultats ne sont pas pertinents : tous les points de couleurs sont mélangés (car on n'a plus seulement en fonction des coordonnées, mais aussi en fonction du temps). Si deux points sont très proches dans le temps, ils seront mis dans un même cluster, bien qu'à vue d'oeil nous ne considérons pas que les points soient très proches géographiquement.

- Il est difficile d'analyser sur *Open Street Map* car nous ne voyons que les points en fonction de leurs coordonnées spatiales alors qu'il faudrait dans l'idéal également voir le résultat des clusters en fonction du temps.

Exemple avec 100 clusters :



Conclusion :


Suite à de nombreuses itérations, nous remarquons que l'algorithme K-means n'est pas stable. Cependant, son utilisation peut être utile pour identifier les grandes zones d'intérêt.

2. Utilisation de l'algorithme Clustering hiérarchique :


Pour utiliser le clustering hiérarchique, il faut réduire le nombre de données. Nous avons donc décidé de nous concentrer sur une zone plus restreinte : une partie du Parc de la Tête d'Or et nous le réglons l'algorithme sur la **latitude** et la **longitude**.

Visualisation avec SINGLE LINK / MIN :

Ce dernier ne donne pas un résultat intéressant car il ne produit qu'un seul gros cluster et de tout petits clusters composés de très peu de points.




Visualisation avec COMPLETE LINK / MAX :



On remarque qu'avec cette valeur, les clusters sont plus définis, même s'ils ne sont pas très denses.

Visualisation avec AVERAGE :


Avec AVERAGE, les clusters sont bien définis. Ce linkage semble plus adapté à notre besoin (identification des points d'intérêt) car il permet de ressortir des clusters plus petits.



Conclusion sur le clustering hiérarchique :

Cet algorithme semble donner des résultats pertinents mais il est aussi très limité en efficacité. Il ne permet pas de traiter un très grand nombre de données et son temps d'exécution est très long (environ 2 min pour 2700 lignes).



3. Utilisation de l'algorithme DBScan :







a. Spatial

Pour utiliser DBSCAN, il faut réduire le nombre de données. Nous avons donc décidé de nous concentrer sur certaines zones qui nous semblaient intéressantes, dans notre cas : le Parc de la Tête d'Or et nous le réglons sur la **latitude** et la **longitude**.

Nous faisons varier la valeur d'épsilon et le nombre de minPoints :

Epsilon	minPoints	Résultat	Commentaire
0,005	6		Mauvais paramétrage : beaucoup de points ont été abandonnés.
0,01	6		Nous obtenons déjà un meilleur paramétrage : moins de bruit (moins de points abandonnés) et plus de clusters visibles.


0,02	6		Nous avons de grands clusters qui se démarquent. Nous distinguons 3 groupes plus denses de points : zoo, les allées centrales autour du lac.
0,02	8		Nous distinguons encore 3 groupes plus denses de points : zoo, les allées centrales autour du lac.


0,02	10		Avec ce paramétrage, nous remarquons l'apparition de clusters bien définis sur des zones du parc
0,015	4		Avec ce dernier paramétrage, nous obtenons les meilleurs résultats : plus de clusters et beaucoup plus définis, et moins de bruit.

b. Spatio-temporel et recherche d'événements

Nous nous intéresserons maintenant à réaliser des clusters spatio-temporels de notre jeu de données en nous concentrant toujours sur la zone de la Tête d'Or. Nous paramétrons l'algorithme DBSCAN sur *lat*, *long*, *date_taken_day*, *date_taken_month*, *date_taken_year* en faisant varier la valeur d'*epsilon* et le nombre de *minPoints*. Nous remarquons que, malgré l'ajout du paramètre temporel, les clusters peuvent être identifiables sur la carte, c'est-à-dire

par leur dimension spatiale. Ainsi, DBSCAN correspond mieux à l'analyse spatio-temporel d'un jeu de données que K-means.

Epsilon	minPoints	Résultat	Commentaire
0,05	6		Nous remarquons que ce réglage de paramètres excluent beaucoup de points de données et forme trop de bruit. Mais nous pouvons tout de même remarquer des petits clusters isolés bien définis.

0,07	6		En augmentant epsilon, nous identifions plus facilement des clusters. Les clusters sont plus gros et nous obtenons moins de bruit.
------	---	---	---

Conclusion sur la recherche des événements :


Le clustering sur les données spatiales et temporelles n'a pas donné des résultats très satisfaisants. En effet, les clusters ne sont pas bien définis et ceci empêche d'identifier les principaux événements dans la zone de la Tête d'Or.

Pour rechercher des événements pertinents, on aurait pu utiliser uniquement du clustering temporel ou essayer avec une autre zone géographique du jeu de données.

IV. Description des points d'intérêts :

Nous souhaitons à présent caractériser nos clusters. A partir des clusters que nous avons obtenus dans la zone de la Tête d'Or à Lyon, nous allons chercher les centres d'intérêts qui se démarquent.


1. Introduction



Tout d'abord, nous utilisons le workflow sur Moodle pour s'initier à l'exploitation des tags. Nous avons d'abord obtenu le "tagcloud" de la Tête d'Or. A partir du jeu de données de la Tête d'Or, nous visualisons les tags les plus visibles (la taille de l'écriture des mots étant proportionnelle au nombre de fois où le tag est utilisé pour caractériser une photo).




Le workflow récupéré nous permet également de créer une matrice binaire de présence de chaque tag pour chaque photo (lorsque le tag est présent dans la photo, la valeur de la cellule correspondante dans la matrice est 1).



Row ID	D fenc	D anticon...	D mus@...	D fresque...	D peintur...	D mus@...	D fresque...	D peintur...	D mus@...	D abstrac...	D photog...	D rhâ'nealp	D parciel...	D parkdel...
Row2_Row5291	0	1	1	1	1	0	0	0	0	0	0	0	0	0
Row3_Row5320	0	0	0	1	1	0	1	1	1	0	0	0	0	0
Row4_Row5295	0	0	0	0	0	0	0	0	0	1	0	0	0	0
Row5_Row1519	0	0	0	0	0	0	0	0	0	0	0	0	0	0
Row6_Row1518	0	0	0	0	0	0	0	0	0	0	0	0	0	0
Row7_Row2759	0	0	0	0	0	0	0	0	0	0	1	0	0	0
Row8_Row2758	0	0	0	0	0	0	0	0	0	0	1	0	0	0
Row9_Row2888	0	0	0	0	0	0	0	0	0	0	1	0	0	0
Row10_Row2...	0	0	0	0	0	0	0	0	0	0	1	0	0	0
Row11_Row2...	0	0	0	0	0	0	0	0	0	0	1	0	0	0
Row12_Row2...	0	0	0	0	0	0	0	0	0	0	1	0	0	0
Row13_Row1...	0	0	0	0	0	0	0	0	0	0	0	1	0	0
Row14_Row1...	0	0	0	0	0	0	0	0	0	0	0	0	1	0
Row15_Row1...	0	0	0	0	0	0	0	0	0	0	0	0	0	1
Row16_Row1...	0	0	0	0	0	0	0	0	0	0	0	0	0	1
Row17_Row1...	0	0	0	0	0	0	0	0	0	0	0	0	0	1
Row18_Row1...	0	0	0	0	0	0	0	0	0	0	0	0	0	1
Row19_Row1...	0	0	0	0	0	0	0	0	0	0	0	0	0	1
Row20_Row1...	0	0	0	0	0	0	0	0	0	0	0	1	0	0
Row21_Row1...	0	0	0	0	0	0	0	0	0	0	0	1	0	0
Row22_Row1...	0	0	0	0	0	0	0	0	0	0	0	1	0	0
Row23_Row1...	0	0	0	0	0	0	0	0	0	0	0	1	0	0
Row24_Row1...	0	0	0	0	0	0	0	0	0	0	0	1	0	0
Row25_Row1...	0	0	0	0	0	0	0	0	0	0	0	1	0	0
Row26_Row1...	0	0	0	0	0	0	0	0	0	0	0	1	0	0
Row27_Row1...	0	0	0	0	0	0	0	0	0	0	0	1	0	0
Row28_Row1...	0	0	0	0	0	0	0	0	0	0	0	1	0	0
Row29_Row1...	0	0	0	0	0	0	0	0	0	0	0	1	0	0
Row30_Row1...	0	0	0	0	0	0	0	0	0	0	0	1	0	0
Row31_Row1...	0	0	0	0	0	0	0	0	0	0	0	1	0	0
Row32_Row1...	0	0	0	0	0	0	0	0	0	0	0	1	0	0
Row33_Row1...	0	0	0	0	0	0	0	0	0	0	0	1	0	0
Row34_Row1...	0	0	0	0	0	0	0	0	0	0	0	1	0	0
Row35_Row1...	0	0	0	0	0	0	0	0	0	0	0	1	0	0
Row36_Row1...	0	0	0	0	0	0	0	0	0	0	0	1	0	0

Pour se concentrer sur la caractérisation d'un cluster, on utilise *Row Filter* sur l'attribut *Winner Cluster*. Nous pouvons ainsi obtenir le nuage de mots et la matrice binaire de présence de chaque tag sur les photos du cluster.



Par exemple, si nous choisissons d'analyser le cluster 1, nous observons le nuage de mots et la matrice binaire ci-dessous. Le nuage de mots permet de mettre en avant les mots les plus utilisés pour tagger les photos de ce cluster, et la matrice binaire marque la présence ou non d'un tag sur une photo du cluster en question. Il est clair que le tag le plus utilisé dans notre cas (peu importe le cluster sélectionné) est celui qui indique le lieu du Parc de la Tête d'Or.




Row ID	D parc delatête d'or	D monochromatic	D tête	D nandoued arwin	D darwin	D cerf
Row0_Row14...	1	0	0	0	0	0
Row1_Row14...	1	0	0	0	0	0
Row2_Row65...	1	0	0	0	0	0
Row3_Row16...	1	1	0	0	0	0
Row4_Row65...	1	0	0	0	0	0
Row5_Row11...	1	0	0	0	0	0
Row6_Row4168	0	0	1	0	0	0
Row7_Row65...	1	0	0	1	1	0
Row8_Row6353	0	0	1	0	0	1
Row9_Row6354	0	0	1	0	0	1

2. Association des tags aux clusters

Le but de cette partie de l'étude est de déterminer les différents tags associés aux photos afin de pouvoir identifier les centres d'intérêt liés à chaque zone.

Dans notre cas, nous choisissons de traiter la zone du Parc de la Tête d'Or.

Nous travaillons avec le bloc *Association Rule Learner* qui permet de retrouver des Itemsets des tags pour chaque cluster et nous faisons varier le minimum support.



Cluster	Minimum support	Résultat																																																								
14	0,2	<table><tr><th>Row ID</th><th>D</th><th>Suppor...</th><th>[...] Items</th></tr><tr><td>item set 0</td><td>0.4</td><td></td><td>[watus,cetartiodactyl,bovidă@,...</td></tr><tr><td>item set 1</td><td>0.6</td><td></td><td>[reduncina,mammifă`r,kobusme...</td></tr><tr><td>item set 2</td><td>1</td><td></td><td>[lyon]</td></tr><tr><td>item set 3</td><td>1</td><td></td><td>[animal]</td></tr><tr><td>item set 4</td><td>1</td><td></td><td>[bovin]</td></tr><tr><td>item set 5</td><td>1</td><td></td><td>[rhă`nealp]</td></tr><tr><td>item set 6</td><td>1</td><td></td><td>[parcdelată@tedor]</td></tr><tr><td>item set 7</td><td>1</td><td></td><td>[franc]</td></tr><tr><td>item set 8</td><td>1</td><td></td><td>[rhă`ne]</td></tr><tr><td>item set 9</td><td>1</td><td></td><td>[bovida]</td></tr><tr><td>item set 10</td><td>1</td><td></td><td>[dor]</td></tr><tr><td>item set 11</td><td>1</td><td></td><td>[parc]</td></tr><tr><td>item set 12</td><td>1</td><td></td><td>[tă@te]</td></tr></table>	Row ID	D	Suppor...	[...] Items	item set 0	0.4		[watus,cetartiodactyl,bovidă@,...	item set 1	0.6		[reduncina,mammifă`r,kobusme...	item set 2	1		[lyon]	item set 3	1		[animal]	item set 4	1		[bovin]	item set 5	1		[rhă`nealp]	item set 6	1		[parcdelată@tedor]	item set 7	1		[franc]	item set 8	1		[rhă`ne]	item set 9	1		[bovida]	item set 10	1		[dor]	item set 11	1		[parc]	item set 12	1		[tă@te]
Row ID	D	Suppor...	[...] Items																																																							
item set 0	0.4		[watus,cetartiodactyl,bovidă@,...																																																							
item set 1	0.6		[reduncina,mammifă`r,kobusme...																																																							
item set 2	1		[lyon]																																																							
item set 3	1		[animal]																																																							
item set 4	1		[bovin]																																																							
item set 5	1		[rhă`nealp]																																																							
item set 6	1		[parcdelată@tedor]																																																							
item set 7	1		[franc]																																																							
item set 8	1		[rhă`ne]																																																							
item set 9	1		[bovida]																																																							
item set 10	1		[dor]																																																							
item set 11	1		[parc]																																																							
item set 12	1		[tă@te]																																																							
77	0,2	<table><tr><th>Row ID</th><th>D</th><th>Support(0-1):</th><th>[...] Items</th></tr><tr><td>item set 0</td><td>0.2</td><td></td><td>[giraff,giraf]</td></tr><tr><td>item set 1</td><td>0.2</td><td></td><td>[velo,bik,franc,...]</td></tr><tr><td>item set 2</td><td>0.2</td><td></td><td>[tă@te,dor,parcdelată@tedor,...]</td></tr><tr><td>item set 3</td><td>0.4</td><td></td><td>[giraf]</td></tr><tr><td>item set 4</td><td>0.6</td><td></td><td>[franc,lyon]</td></tr><tr><td>item set 5</td><td>0.8</td><td></td><td>[lyon]</td></tr></table>	Row ID	D	Support(0-1):	[...] Items	item set 0	0.2		[giraff,giraf]	item set 1	0.2		[velo,bik,franc,...]	item set 2	0.2		[tă@te,dor,parcdelată@tedor,...]	item set 3	0.4		[giraf]	item set 4	0.6		[franc,lyon]	item set 5	0.8		[lyon]																												
Row ID	D	Support(0-1):	[...] Items																																																							
item set 0	0.2		[giraff,giraf]																																																							
item set 1	0.2		[velo,bik,franc,...]																																																							
item set 2	0.2		[tă@te,dor,parcdelată@tedor,...]																																																							
item set 3	0.4		[giraf]																																																							
item set 4	0.6		[franc,lyon]																																																							
item set 5	0.8		[lyon]																																																							
12	0,2	<table><tr><th>Row ID</th><th>D</th><th>Suppor...</th><th>[...] Items</th></tr><tr><td>item set 0</td><td>0.222</td><td></td><td>[tă@te,dor,parc,...]</td></tr><tr><td>item set 1</td><td>0.222</td><td></td><td>[nikon,blackwhit,monkey,...]</td></tr><tr><td>item set 2</td><td>0.222</td><td></td><td>[tă@te,lă@mur,ventrereux,...]</td></tr><tr><td>item set 3</td><td>0.333</td><td></td><td>[nikon]</td></tr><tr><td>item set 4</td><td>0.444</td><td></td><td>[tă@te,parcdelată@tedor,dor,...]</td></tr><tr><td>item set 5</td><td>0.556</td><td></td><td>[parcdelată@tedor]</td></tr><tr><td>item set 6</td><td>0.667</td><td></td><td>[tă@te,dor,parc]</td></tr><tr><td>item set 7</td><td>1</td><td></td><td>[lyon]</td></tr></table>	Row ID	D	Suppor...	[...] Items	item set 0	0.222		[tă@te,dor,parc,...]	item set 1	0.222		[nikon,blackwhit,monkey,...]	item set 2	0.222		[tă@te,lă@mur,ventrereux,...]	item set 3	0.333		[nikon]	item set 4	0.444		[tă@te,parcdelată@tedor,dor,...]	item set 5	0.556		[parcdelată@tedor]	item set 6	0.667		[tă@te,dor,parc]	item set 7	1		[lyon]																				
Row ID	D	Suppor...	[...] Items																																																							
item set 0	0.222		[tă@te,dor,parc,...]																																																							
item set 1	0.222		[nikon,blackwhit,monkey,...]																																																							
item set 2	0.222		[tă@te,lă@mur,ventrereux,...]																																																							
item set 3	0.333		[nikon]																																																							
item set 4	0.444		[tă@te,parcdelată@tedor,dor,...]																																																							
item set 5	0.556		[parcdelată@tedor]																																																							
item set 6	0.667		[tă@te,dor,parc]																																																							
item set 7	1		[lyon]																																																							
14	0,5	<table><tr><th>Row ID</th><th>D</th><th>Suppor...</th><th>[...] Items</th></tr><tr><td>item set 0</td><td>0.6</td><td></td><td>[reduncina,mammifă`r,kobusmegaceros,...</td></tr><tr><td>item set 1</td><td>1</td><td></td><td>[lyon]</td></tr><tr><td>item set 2</td><td>1</td><td></td><td>[animal]</td></tr><tr><td>item set 3</td><td>1</td><td></td><td>[bovin]</td></tr><tr><td>item set 4</td><td>1</td><td></td><td>[rhă`nealp]</td></tr><tr><td>item set 5</td><td>1</td><td></td><td>[parcdelată@tedor]</td></tr><tr><td>item set 6</td><td>1</td><td></td><td>[franc]</td></tr><tr><td>item set 7</td><td>1</td><td></td><td>[rhă`ne]</td></tr><tr><td>item set 8</td><td>1</td><td></td><td>[bovida]</td></tr><tr><td>item set 9</td><td>1</td><td></td><td>[dor]</td></tr><tr><td>item set 10</td><td>1</td><td></td><td>[parc]</td></tr><tr><td>item set 11</td><td>1</td><td></td><td>[tă@te]</td></tr></table>	Row ID	D	Suppor...	[...] Items	item set 0	0.6		[reduncina,mammifă`r,kobusmegaceros,...	item set 1	1		[lyon]	item set 2	1		[animal]	item set 3	1		[bovin]	item set 4	1		[rhă`nealp]	item set 5	1		[parcdelată@tedor]	item set 6	1		[franc]	item set 7	1		[rhă`ne]	item set 8	1		[bovida]	item set 9	1		[dor]	item set 10	1		[parc]	item set 11	1		[tă@te]				
Row ID	D	Suppor...	[...] Items																																																							
item set 0	0.6		[reduncina,mammifă`r,kobusmegaceros,...																																																							
item set 1	1		[lyon]																																																							
item set 2	1		[animal]																																																							
item set 3	1		[bovin]																																																							
item set 4	1		[rhă`nealp]																																																							
item set 5	1		[parcdelată@tedor]																																																							
item set 6	1		[franc]																																																							
item set 7	1		[rhă`ne]																																																							
item set 8	1		[bovida]																																																							
item set 9	1		[dor]																																																							
item set 10	1		[parc]																																																							
item set 11	1		[tă@te]																																																							

77	0,5	<table><tr><th>Row ID</th><th>D</th><th>Suppor...</th><th>[...] Items</th></tr><tr><td>item set 0</td><td>0.6</td><td></td><td>[franc,lyon]</td></tr><tr><td>item set 1</td><td>0.8</td><td></td><td>[lyon]</td></tr></table>	Row ID	D	Suppor...	[...] Items	item set 0	0.6		[franc,lyon]	item set 1	0.8		[lyon]																																				
Row ID	D	Suppor...	[...] Items																																															
item set 0	0.6		[franc,lyon]																																															
item set 1	0.8		[lyon]																																															
12	0,5	<table><tr><th>Row ID</th><th>D</th><th>Suppor...</th><th>[...] Items</th></tr><tr><td>item set 0</td><td>0.556</td><td></td><td>[parcdelatãted...</td></tr><tr><td>item set 1</td><td>0.667</td><td></td><td>[tãte,dor,parc]</td></tr><tr><td>item set 2</td><td>1</td><td></td><td>[lyon]</td></tr></table>	Row ID	D	Suppor...	[...] Items	item set 0	0.556		[parcdelatãted...	item set 1	0.667		[tãte,dor,parc]	item set 2	1		[lyon]																																
Row ID	D	Suppor...	[...] Items																																															
item set 0	0.556		[parcdelatãted...																																															
item set 1	0.667		[tãte,dor,parc]																																															
item set 2	1		[lyon]																																															
14	0,8	<table><tr><th>Row ID</th><th>D</th><th>Suppor...</th><th>[...] Items</th></tr><tr><td>item set 0</td><td>1</td><td></td><td>[lyon]</td></tr><tr><td>item set 1</td><td>1</td><td></td><td>[animal]</td></tr><tr><td>item set 2</td><td>1</td><td></td><td>[bovin]</td></tr><tr><td>item set 3</td><td>1</td><td></td><td>[rhã'nealp]</td></tr><tr><td>item set 4</td><td>1</td><td></td><td>[parcdelatãtedor]</td></tr><tr><td>item set 5</td><td>1</td><td></td><td>[franc]</td></tr><tr><td>item set 6</td><td>1</td><td></td><td>[rhã'ne]</td></tr><tr><td>item set 7</td><td>1</td><td></td><td>[bovida]</td></tr><tr><td>item set 8</td><td>1</td><td></td><td>[dor]</td></tr><tr><td>item set 9</td><td>1</td><td></td><td>[parc]</td></tr><tr><td>item set 10</td><td>1</td><td></td><td>[tãte]</td></tr></table>	Row ID	D	Suppor...	[...] Items	item set 0	1		[lyon]	item set 1	1		[animal]	item set 2	1		[bovin]	item set 3	1		[rhã'nealp]	item set 4	1		[parcdelatãtedor]	item set 5	1		[franc]	item set 6	1		[rhã'ne]	item set 7	1		[bovida]	item set 8	1		[dor]	item set 9	1		[parc]	item set 10	1		[tãte]
Row ID	D	Suppor...	[...] Items																																															
item set 0	1		[lyon]																																															
item set 1	1		[animal]																																															
item set 2	1		[bovin]																																															
item set 3	1		[rhã'nealp]																																															
item set 4	1		[parcdelatãtedor]																																															
item set 5	1		[franc]																																															
item set 6	1		[rhã'ne]																																															
item set 7	1		[bovida]																																															
item set 8	1		[dor]																																															
item set 9	1		[parc]																																															
item set 10	1		[tãte]																																															
77	0,8	<table><tr><th>Row ID</th><th>D</th><th>Suppor...</th><th>[...] Items</th></tr><tr><td>item set 0</td><td>0.8</td><td></td><td>[lyon]</td></tr></table>	Row ID	D	Suppor...	[...] Items	item set 0	0.8		[lyon]																																								
Row ID	D	Suppor...	[...] Items																																															
item set 0	0.8		[lyon]																																															
12	0,8	<table><tr><th>Row ID</th><th>D</th><th>Suppor...</th><th>[...] Items</th></tr><tr><td>item set 0</td><td>1</td><td></td><td>[lyon]</td></tr></table>	Row ID	D	Suppor...	[...] Items	item set 0	1		[lyon]																																								
Row ID	D	Suppor...	[...] Items																																															
item set 0	1		[lyon]																																															

Discussion du résultat :

Nous remarquons qu'en augmentant le support, on a moins d'itemsets. Ainsi, pour avoir un itemset de tags pertinent, il faut diminuer le support.

Cependant, ceci dépend de chaque cluster. Nous remarquons par exemple que pour le cluster 14, l'itemset des tags est pertinent même en augmentant le support. Cela peut permettre par exemple au Grand Lyon d'identifier les principaux centres d'intérêt d'une zone, afin de pouvoir orienter leurs activités touristiques vers ces centres d'intérêt. Nous remarquons notamment que l'ensemble des tags mentionne des mots-clés liés aux animaux.

Toutefois, pour les clusters 77 et 11 le résultat n'est pas exploitable, même avec une valeur petite du support. Les seuls ensembles de tags obtenus indiquent que les photos sont à Lyon et en France. Nous pourrions aller plus loin et tenter de restreindre l'analyse de tags à des tags plus pertinents. Pour cela, nous pourrions ne pas prendre en compte les tags "lyon" ou "franc" car nous savons que ces informations n'intéresseront pas le Grand Lyon, qui sait dans quelle ville et pays il se situe.

On peut ainsi déduire des tags que ces trois clusters (14, 77, 12) peuvent correspondre au parc zoologique de la Tête d'or, par la présence des mots comme "animal", "giraffe", "monkey"...